

기계 학습 기말 프로젝트: FMCC

(Female-Male Classification Challenge)

컴퓨터공학부 김우일

2023 봄학기

팀 주제 선정 결과



- GMM 기반: 총 10팀
 - JJ, 기개있는학습, 개구리애호가, 풍비박산, 학습좋아, 너목보, 2021, 인 천논현, DX, 냥냥냥인천대

- 신경망 기반: 총 12팀
 - OpenML, J.Tree, 고수, 화자의심경망, 공일즈, 상재, Embryo, 권태형, smile, 심현수, CE, 이승우

- 기타(SVM, 비모수 기법 등) : 총 11팀
 - Gust, 기하하하학, Naruto, 딥뉴럴마인드, Voyager, 유하, 머신러닝의신, MM, 강력한컴공, 박남수, 황재영



- 학습 데이터
 - 남녀 각각 25명, 화자 별 200 발음: 총 10,000 샘플
 - 3-5 음절로 이루어진 한국어 단어
 - 생활 잡음에 오염된 상태
 - 거실 TV 방송 배경 잡음
 - 202301ml/raw16k/train
 - 파일 네임 리스트: fmcc_train.ctl

FCJY0/FCJY0_pbw1001 FCJY0/FCJY0_pbw1002 FCJY0/FCJY0_pbw1003 FCJY0/FCJY0_pbw1004 FCJY0/FCJY0_pbw1005

MBTG0/MBTG0_pbw1001 MBTG0/MBTG0_pbw1002 MBTG0/MBTG0_pbw1003 MBTG0/MBTG0_pbw1004 MBTG0/MBTG0_pbw1005

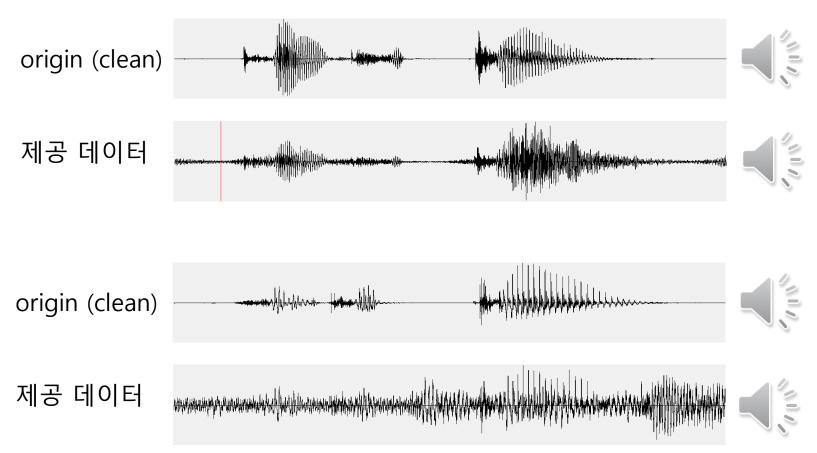


- 테스트 데이터
 - 남 500 샘플, 여 500 샘플: 총 1,000 샘플
 - 3-5 음절로 이루어진 한국어 단어
 - 학습 데이터와 동일한 종류의 생활 잡음에 오염된 상태
 - 202301ml/raw16k/test
 - 파일 네임 리스트: fmcc_test.ctl
 - 라벨(Labeled) 데이터: fmcc_test_ref.txt

fmcc_test_0001	fmcc_test_0001 feml
fmcc_test_0002	fmcc_test_0002 feml
fmcc_test_0003	fmcc_test_0003 feml
fmcc_test_0004	fmcc_test_0004 feml
fmcc_test_0005	fmcc_test_0005 feml
fmcc_test_0501	fmcc_test_0501 male
fmcc_test_0502	fmcc_test_0502 male
fmcc_test_0503	fmcc_test_0503 male
fmcc_test_0504	fmcc_test_0504 male
fmcc_test_0505	fmcc_test_0505 male



- 음성 데이터 포맷
 - PCM 파일 포맷, WAV 파일에서 헤더 없는 형태
 - 16kHz, 16bit linear encoding, mono channel, little endian





- 평가용 스크립트 파일
 - Perl 스크립트: eval.pl
 - 입력: 테스트 결과 파일(예시), 라벨 데이터 파일

```
@text true = <TRUE>;
@text test = <TEST>;
n = 0;
$hit = 0;
foreach $line test (@text test){
   chomp($line test);
   my @sbuf test = split / /, $line test;
   $line true = $text true[$n];
   chomp($line true);
   my @sbuf true = split / /, $line true;
   if ($sbuf test[1] eq $sbuf true[1]) {
       hit = hit + 1;
   #print "$line result\n";
   n = n + 1;
total = n;
$acc = $hit / $total * 100;
print "======= Results Analysis =======\n";
print "Test: $ARGV[0]\n";
print "True: $ARGV[1]\n";
print "Accuracy: ", sprintf("%.2f", ${acc}), "\%\n";
print "Hit: $hit, Total: $total\n";
close(TRUE);
close(TEST);
```

```
/home/wikim/exp/raw16k/test/fmcc test 0972.raw male
/home/wikim/exp/raw16k/test/fmcc_test_0973.raw_male
/home/wikim/exp/raw16k/test/fmcc test 0974.raw feml
/home/wikim/exp/raw16k/test/fmcc test 0975.raw male
/home/wikim/exp/raw16k/test/fmcc test 0976.raw male
/home/wikim/exp/raw16k/test/fmcc test 0977.raw male
/home/wikim/exp/raw16k/test/fmcc test 0978.raw male
/home/wikim/exp/raw16k/test/fmcc test 0979.raw feml
/home/wikim/exp/raw16k/test/fmcc test 0980.raw male
/home/wikim/exp/raw16k/test/fmcc test 0981.raw male
/home/wikim/exp/raw16k/test/fmcc test 0982.raw male
/home/wikim/exp/raw16k/test/fmcc test 0983.raw male
/home/wikim/exp/raw16k/test/fmcc test 0984.raw male
/home/wikim/exp/raw16k/test/fmcc test 0985.raw male
/home/wikim/exp/raw16k/test/fmcc test 0986.raw feml
/home/wikim/exp/raw16k/test/fmcc test 0987.raw male
/home/wikim/exp/raw16k/test/fmcc test 0988.raw male
```

결과물 제출

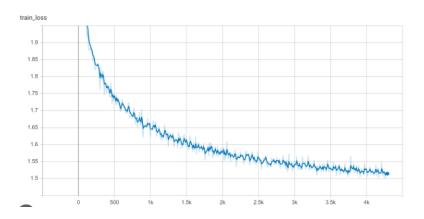


- (1) 학습용 코드
 - 코드에 주석으로 주요 기능 설명
- (2) 모델
- (3) 테스트용 코드
 - 코드에 주석으로 주요 기능 설명
 - 입력: 테스트 데이터 (음성 파형, *.raw) 리스트
 - 출력: 테스트 결과 파일 (제공된 예시와 동일한 형식)
 - 제출한 모델과 테스트용 코드로 동일한 결과로 재현되어야 함
 - 스크립트 형식의 코드만 허용, 바이너리 형태의 실행 파일 제출 불가
- (4) 제공된 테스트 데이터에 대한 테스트 결과 파일
 - 팀명_test_results.txt
- (5) 실행 설명서
 - 코드 실행을 위한 설명서
 - 만일 테스트용 코드 실행을 위해 설치해야 할 package, library 등이 있다면 이에 대한 상세한 설명
 - 특별한 형식 없음(hwp, ppt, doc 등)

결과물 제출



- (6) 2페이지 논문 형식 결과 보고서
 - 정보과학회 학술대회 논문 형식 (*.hwp)
 - 사용한 기법, 모델 구조, 실험 환경(머신 스펙, SW 종류, OS 등), 실험 결과 등에 대해 상세히 작성
 - 필수 포함: 학습률 곡선, eval.csh 실행 결과 캡쳐, 모델 사이즈(파라미터 개수 및 실제 파일 크기), 코드 출처(참고문헌)
 - 반드시 2 페이지로 작성



- (7) 학교 표절 SW 검사 결과
 - Copy killer
 - 작성한 2페이지 논문 형식 결과 보고서 표절 검사 결과
- 제출 마감: 6월 14일 (수) 23:59
 - (1)~(7) 결과물을 1개의 압축파일로 제출 (*.zip)

평가 데이터 결과 제출



- 평가 데이터 공개
 - LMS 시스템, 6월 15일 (목) 12:00
 - 1,000 샘플, 파일 리스트(fmcc_eval.ctl)
 - 테스트 데이터와 동일한 파일 형식
 - "당연히" 라벨 데이터 (ground truth) 미 제공

- 평가 데이터 테스트 결과 제출
 - 제출한 모델과 테스트 코드에서 입력 데이터만 평가 데이터로 교체하여 실행한 결과 제출
 - 결과 파일명: 팀명_eval_results.txt
 - 제출 마감: 6월 15일 (목) 23:59
 - 제출한 모델과 테스트 코드로 재현 불가능 시 0점 처리

Note



- 팀 구성원은 동일 기말 성적 부여
- 성능 향상 목표
 - 파라미터 최적화, 모델 구조 변경, 전처리, 특징 변환, 후처리 등
 - 제공된 학습데이터, 테스트데이터 최대 활용
 - 테스트데이터 결과와 평가데이터 결과는 유사할 것으로 예상됨
- 시스템 결합 허용 조건
 - 예) GMM 기반 주제팀인데 신경망 시스템과 결합 가능?
 - GMM 기반 주제팀이 신경망 시스템과 결합 가능한 조건
 - 팀 주제의 시스템이 main이 되어야 함
 - 시스템 성능: GMM+신경망 > GMM 단독 > 신경망 단독
 - 결과보고서에 해당 내용 필수 포함
- 외부 데이터 사용, 데이터 증강 허용
 - 결과보고서에 해당 내용 필수 포함

평가



- 기말 고사 100%
- 성능평가(40%)
 - 평가데이터 결과를 각 그룹별 랭킹
 - 분류 정확도, 모델 사이즈, 테스트데이터 결과 등 고려
- 기술평가(40%), 결과 보고서(20%)
 - 수업 내용에 대한 이해도 및 반영 정도
 - 사용 기술에 대한 이해도
 - 독창성
 - State-of-the-art 기술인지는 중요하지 않음
 - 보고서 작성의 충실도
 - 필수 요소 포함 여부 등
- 필요시 시스템 동작 확인 예정
- 부정행위 적발 시 F 처리
 - 코드 출처 명기 (결과보고서), 표절 검사 결과 제출
- 프로젝트 진행에 따라 제출물, 평가 방법이 일부 변경될 수 있음^^;;

일정



주 차	내 용
9주차 (4월 27일 - 5월 3일)	팀 구성
10주차 (5월 4 - 10일)	그룹 배정, 데이터 제공
11주차 (5월 11 - 17일)	프로젝트 진행
12주차 (5월 18 - 24일)	프로젝트 진행
13주차 (5월 25 - 31일)	프로젝트 진행
14주차 (6월 1 - 7일)	프로젝트 진행
15주차 (6월 8 – 14일)	결과물 제출 마감: 6월 14일 (수) 23:59
6월 15일 (목)	평가용 데이터 결과 제출 데이터 공개: 12:00 (낮 12시) 결과 제출 마감: 23:59
16주차 (6월 15 – 21일)	팀 별 시스템 동작 확인 (필요시)